

Práctica 1

Fernando Luis Pinilla Molina
Hugo Herrero González
Ignacio Freijeiro Tapia
Alfonso Ramos Rojas

fernand925@uma.es
hugohg@uma.es
nacho.freijeiro@uma.es
alfonsram@uma.es

Aprendizaje Automático. Universidad De Málaga

Esta práctica introduce el uso de Python y sus librerías esenciales para el aprendizaje automático (NumPy, Pandas, Matplotlib, Scikit-learn). Siguiendo un ejemplo previo con el dataset Iris, aplicamos operaciones similares de exploración de datos, cálculo estadístico, visualización y entrenamiento de un modelo sobre el dataset de Cáncer de Mama de Wisconsin, disponible en Scikit-learn.

1 Introducción

El proyecto se centra en el análisis exploratorio y posterior aplicación de un modelo de aprendizaje automático sobre el conjunto de los datos de Breast Cancer Wisconsin. El dataset es un recurso estándar que se usa en Machine Learning para los problemas de clasificación binaria. Nuestro objetivo principal es predecir si la masa celular mamaria es Maligna o no Benigna, las indicamos con la etiqueta 0 o 1 respectivamente. Para predecir cual es cada una nos basamos en características digitalizadas de las muestras clínicas. Para comprobarlos, hemos generado un modelo usando una clasificación por árbol de decisión.

2 Análisis Gráficas

2.1 Histograma de Radio Medio




Fig. 1. Histograma del radio medio

Este histograma ilustra la distribución de frecuencias de la característica **radio medio** (el radio promedio de los núcleos celulares) en el conjunto de datos de *Cáncer de Mama*.

El eje X representa los valores del radio medio, mientras que el eje Y indica la frecuencia, es decir, cuántas muestras (tumores) presentan un radio medio dentro de cada intervalo (*bin*).

Se observa que la mayoría de las muestras tienen un radio medio concentrado entre aproximadamente **10 y 15**, con la frecuencia más alta (un poco más de 175 muestras) situándose en el intervalo alrededor de los valores **12–13**.

La distribución presenta un **sesgo hacia la derecha** (asimetría positiva), indicando que hay menos muestras con radios medios muy grandes (por encima de 20), pero estos valores más altos extienden la cola de la distribución en esa dirección.

Por otro lado, si observamos los datos estadísticos que hemos conseguido a través de NumPy, complementan esta visión:

- **Media del radio medio:** 14.13
- **Mediana:** 13.37

El hecho de que la media sea ligeramente superior a la mediana es consistente con el sesgo a la derecha observado en el histograma.

En resumen, el histograma muestra que los **radios medios más pequeños y medianos son los más comunes** en las muestras, con una disminución progresiva en la frecuencia a medida que el radio medio aumenta.

2.2 Dispersión por tipo de tumor

La gráfica 2 nos muestra la correlación entre el Radio Medio y la Textura Media. Cada punto que nos aparece nos representa una muestra, y usamos la codificación por color según la clase de tumor que sea:

- Maligno: Color rojo
- Benigno: Color Verde

De la gráfica podemos extraer diferentes conclusiones sobre la separación de los datos.

1. **Separación de clases:** Podemos observar que los tumores benignos se agrupan en la región de los valores bajos para el radio medio y la textura media, mientras que los tumores malignos se agrupan en la región de los valores más altos para el radio medio y la textura media.
2. **Utilidad:** También vemos que el radio medio es muy efectivo para la separación, ya que los puntos con un radio medio pequeño son casi exclusivamente benignos, y los puntos con un radio medio grande son mayoritariamente malignos.
3. **Región de Ambigüedad:** Podemos ver en la gráfica que tenemos una región de ambigüedad, principalmente en la zona central. En el área esta, vemos que las muestras de ambas clases se comienzan a mezclar, lo que nos indica que una clasificación perfecta usando solo estas dos variables sería prácticamente imposible y nos generaría los pocos errores de clasificación que podemos ver en la matriz de confusión.




Fig. 2. Dispersión por tipo de tumor

2.3 Número de tumores por clase

En la gráfica podemos ver que tenemos más casos de tumores benignos que malignos, por lo que el conjunto de datos presenta un desequilibrio de clases que puede influir en los resultados de los modelos predictivos. Por ello, podría ser recomendable aplicar alguna técnica de balanceo de datos.




Fig. 3. Número de tumores por clase

2.4 Gráfica comparación medidas

En esta gráfica podemos observar que tanto el radio medio como la textura media son menores en los casos benignos, esto puede indicarnos que los tumores malignos tienden a ser más grandes y a tener una estructura más heterogénea en su textura. Es decir, podemos concluir que existe una relación clara entre las características físicas del tumor y su naturaleza (maligna o benigna).




Fig. 4. Comparación de medidas promedio por clase

2.5 Radio Medio Por Clase

Sobre el análisis de las medias con respecto a la clase en la gráfica 5:

- Los tumores malignos tienen una dispersión de valores mucho mas grande que los benignos
- Los tumores malignos presentan un radio medio (17.5cm) muy superior al de los benignos (12.5cm).




Fig. 5. Boxplot del radio medio

3 Análisis Modelo

Para terminar esta práctica hemos generado un modelo predictivo simple usando clasificación por árbol de decisión. Para ello, hemos usado parte del conjunto de datos para entrenamiento y luego el resto de datos para evaluar su rendimiento. Finalmente, hemos utilizado el (*accuracy score*) para obtener la precisión del modelo, obteniendo aproximadamente 0.95.

Para poder evaluar el modelo por completo, necesitaríamos examinar nuestra matriz de confusión. Si bien obtener una precisión tan alta podría llegar a ser un indicio de buen rendimiento, existe la posibilidad de sobreajuste, donde el modelo se memoriza el conjunto de entrenamiento y podría llegar a no generalizar los datos nuevos. Por lo que recomendamos también reportar el Recall y el F1-Score para poder confirmar que el modelo es efectivo identificando tumores malignos.




Fig. 6. Matriz de Confusión

Viendo la matriz de confusión, observamos que el modelo muestra un excelente desempeño en la clasificación de tumores malignos y benignos. De los 114 casos totales, solo se produjeron 6 errores (3 falsos positivos y 3 falsos negativos), lo que indica un nivel muy bajo de confusión entre las clases.

Tanto el recall como el F1-score que obtenemos es aproximadamente de 0.96, lo que refleja una alta capacidad del modelo para identificar correctamente los casos positivos (malignos) sin perder precisión.